1 Определение целевых микрокатегорий

<u>До 5 баллов</u>
Для каждого объявления решение возвращает набор целевых микрокатегорий - значения mcId из списка drafts.
Эталон содержит микрокатегории, для которых следует создать дополнительные объявления. Исходная микрокатегория в эталонный набор не включается. Если дополнительные черновики не нужны, эталонный набор пуст.
Для объявления i считаются:
TPi - число предсказанных микрокатегорий, которые есть в эталоне;
FPi - число предсказанных микрокатегорий, которых нет в эталоне;
FNi - число микрокатегорий из эталона, которые решение пропустило;
Счётчики суммируются по всем N объявлениям проверочного набора:

$$micro - F1 = \frac{2\sum_{i=1}^{N} TP_i}{2\sum_{i=1}^{N} TP_i + \sum_{i=1}^{N} FP_i + \sum_{i=1}^{N} FN_i}$$

Например, если эталонный набор — {102, 104}, а решение вернуло {102, 105}, результат для объявления: один TP, один FP и один FN.
Баллы за классификацию = 5 × micro-F1.
Во второй день соревнований участникам будет предоставлен проверочный набор данных. Оценка классификации по micro-F1 будет проводиться по результатам работы решений на этом наборе.
Повтор одного mcId не увеличивает число правильных ответов.
Для расчёта метрики используйте готовую реализацию sklearn.metrics.f1_score с параметром average="micro". Эталон и предсказания нужно представить как бинарные матрицы: строки соответствуют объявлениям, столбцы — микрокатегориям в одинаковом порядке, 1 означает наличие микрокатегории в наборе, 0 — отсутствие.

2 Работоспособность и проработка решения

<u>До 3 баллов</u>
Жюри оценивает решение по live-демо и ответам команды: работает ли полный сценарий обработки нового объявления, обоснован ли технический подход, учтены ли ошибки, уязвимости и ограничения. Команда должна объяснить устройство решения и возможность его повторного запуска.
При сопоставимом качестве преимущество получают более быстрые и экономичные решения. Приветствуются открытые модели, самостоятельное развёртывание и оптимизация обращений к LLM. Платные API допускаются.
Команда указывает используемые модели и, по возможности, стоимость обработки для итоговой конфигурации.
Сложность архитектуры и оформление презентации сами по себе дополнительных баллов не дают.

3 Качество сгенерированных черновиков

<u>До 2 баллов</u>
На live-демо жюри оценивает пары «исходное объявление -> черновик».
Хороший черновик:

- посвящён целевой микрокатегории и понятен как отдельное объявление;
- сохраняет полезные детали исходника без выдуманных услуг, цен и обещаний;

- написан грамотно и структурированно, без воды, повторов и потери важных сведений.

Плохой черновик: копирует исходное объявление без адаптации, содержит нерелевантные услуги или выдуманные условия, теряет полезные детали либо выглядит как неинформативный шаблон.
Подходящие формулировки исходника можно сохранять: процент совпадения и перефразирование ради уникальности не оцениваются.

Защита и live-демо
На защите команда должна:

- показать работу решения на примерах организаторов в реальном времени: от входного объявления до целевых микрокатегорий и черновиков, если генерация реализована;
- объяснить подход и назвать используемые модели;
- представить показатели скорости и стоимости, разобрать ошибки, уязвимости и ограничения решения.

Скриншоты и запись могут дополнять защиту, но не заменяют live-демо.

Итоговый результат
Итоговый балл — это сумма трёх оценок. При равенстве баллов выше ставится команда с большим micro-F1 на проверочном наборе; при дальнейшем равенстве - с более высокой оценкой работоспособности и проработки решения.